

Étude numérique d'un réseau de Hopfield

Loïc Gnocchini

30 avril 2026

Résumé

Ce rapport présente l'étude numérique d'un réseau de Hopfield bipolaire. L'objectif est d'analyser la stabilité des souvenirs stockés, la robustesse de la récupération face au bruit initial, la taille effective des bassins d'attraction et l'évolution de l'énergie du système. Une règle d'apprentissage de Hebb est d'abord étudiée, puis comparée à une règle d'apprentissage de type perceptron.

Table des matières

1	Introduction	3
2	Méthodologie	3
2.1	Modèle de Hopfield	3
2.2	Apprentissage hebbien	4
2.3	Dynamique du réseau	4
2.4	Fonction d'énergie	4
2.5	Recouvrement avec un souvenir	5
2.6	Bruit initial	5
2.7	Taux de récupération correcte	5
2.8	États parasites	6
2.9	Apprentissage de type perceptron	6
2.10	Paramètres numériques	6

3	Validation du code	7
3.1	Symétrie de la matrice de poids	7
3.2	Décroissance de l'énergie	7
3.3	Stabilité des souvenirs stockés	8
3.4	Validation de la règle perceptron	8
4	Résultats	9
4.1	Robustesse au bruit	9
4.2	Effet du nombre de souvenirs stockés	10
4.3	Évolution de l'énergie	12
4.4	CelebA	13
5	Code	14
6	Analyse et discussion	15
6.1	Visages CelebA	15
6.2	Robustesse et bassins d'attraction	15
6.3	Effet du nombre de souvenirs	15
6.4	Comparaison entre Hebb et perceptron	16
6.5	Interprétation énergétique du perceptron	16
6.6	Limites du modèle et des simulations	17
6.7	Améliorations possibles	17
7	Conclusion	18
8	Annexe	19

1 Introduction

Les réseaux de Hopfield sont des modèles de réseaux de neurones récurrents capables de stocker des souvenirs sous forme d'attracteurs dynamiques. Lorsqu'un état initial bruité est présenté au réseau, la dynamique peut permettre de reconstruire le souvenir stocké le plus proche.

L'objectif de ce projet est d'étudier numériquement les propriétés d'un réseau de Hopfield bipolaire.

Plus précisément, on cherche à répondre aux questions suivantes :

- Comment la robustesse de la récupération dépend-elle du niveau de bruit initial ?
- Comment le nombre de souvenirs stockés influence-t-il la stabilité du réseau ?
- Comment l'énergie évolue-t-elle pendant la convergence ?
- Quelle est la différence entre l'apprentissage hebbien classique et une règle de type perceptron ?
- Quelle est la différence entre des souvenirs aléatoires et des souvenirs similaires ?

L'approche numérique est appropriée puisque le comportement du réseau dépend fortement du nombre de neurones, du nombre de souvenirs stockés, du bruit initial et de la dynamique de mise à jour. La simulation permet donc d'étudier statistiquement la récupération des souvenirs et la structure effective des bassins d'attraction.

2 Méthodologie

2.1 Modèle de Hopfield

On considère un réseau de Hopfield composé de N neurones bipolaires. L'état du neurone i est donné par

$$s_i \in \{-1, +1\}, \quad i = 1, \dots, N. \quad (1)$$

Un état complet du réseau est représenté par le vecteur

$$\mathbf{s}(t) = (s_1(t), s_2(t), \dots, s_N(t)). \quad (2)$$

Les souvenirs stockés sont représentés par des vecteurs bipolaires

$$\boldsymbol{\xi}^\mu = (\xi_1^\mu, \xi_2^\mu, \dots, \xi_N^\mu), \quad \mu = 1, \dots, P, \quad (3)$$

où P est le nombre de souvenirs stockés.

2.2 Apprentissage hebbien

Dans le modèle classique, les poids synaptiques sont construits à partir de la règle de Hebb :

$$w_{ij} = \frac{1}{N} \sum_{\mu=1}^P \xi_i^\mu \xi_j^\mu, \quad i \neq j, \quad (4)$$

avec

$$w_{ii} = 0. \quad (5)$$

Cette règle donne une matrice de poids symétrique :

$$w_{ij} = w_{ji}. \quad (6)$$

2.3 Dynamique du réseau

Le champ local reçu par le neurone i est défini par

$$h_i(t) = \sum_{j=1}^N w_{ij} s_j(t). \quad (7)$$

La mise à jour du neurone est donnée par

$$s_i(t+1) = \text{sgn}(h_i(t)). \quad (8)$$

Si $h_i(t) = 0$, l'état du neurone est conservé :

$$s_i(t+1) = s_i(t). \quad (9)$$

Dans ce projet, on étudie principalement la dynamique asynchrone, où les neurones sont mis à jour un à un. Une comparaison avec la dynamique synchrone peut également être faite lorsque pertinent.

2.4 Fonction d'énergie

Pour une matrice de poids symétrique, la fonction d'énergie du réseau est donnée par

$$E(\mathbf{s}) = -\frac{1}{2} \sum_{i \neq j} w_{ij} s_i s_j. \quad (10)$$

Dans le cas hebbien classique avec mise à jour asynchrone, cette énergie décroît ou reste constante au cours de la dynamique. Elle permet donc d'interpréter les souvenirs comme des minima locaux du paysage énergétique.

2.5 Recouvrement avec un souvenir

La similarité entre l'état du réseau $\mathbf{s}$ et un souvenir $\boldsymbol{\xi}^\mu$ est mesurée par le recouvrement :

$$m^\mu = \frac{1}{N} \sum_{i=1}^N \xi_i^\mu s_i. \quad (11)$$

Un recouvrement $m^\mu \approx 1$ indique que l'état du réseau est très proche du souvenir $\boldsymbol{\xi}^\mu$. Un recouvrement $m^\mu \approx 0$ indique une faible corrélation, tandis qu'un recouvrement négatif indique une ressemblance avec l'inverse du souvenir.

2.6 Bruit initial

Pour tester la robustesse du réseau, un souvenir est bruité en inversant une fraction η de ses composantes. Le bruit est relié à la distance de Hamming :

$$d_H(\mathbf{s}^{(0)}, \boldsymbol{\xi}^\mu) = \sum_{i=1}^N \frac{1 - \xi_i^\mu s_i^{(0)}}{2}. \quad (12)$$

La fraction de bruit est donc

$$\eta = \frac{d_H}{N}. \quad (13)$$

2.7 Taux de récupération correcte

Une récupération est considérée correcte si le recouvrement final avec le souvenir cible dépasse un seuil fixé :

$$m_{\text{cible}} > m_{\text{seuil}}. \quad (14)$$

Dans ce projet, on a pris par exemple

$$m_{\text{seuil}} = 0.95. \quad (15)$$

Le taux de récupération correcte est alors défini par

$$R(\eta) = \frac{N_{\text{succès}}}{N_{\text{essais}}}. \quad (16)$$

2.8 États parasites

Les états parasites sont identifiés à partir du recouvrement maximal

$$m_{\max} = \max_{\mu \in \{1, \dots, P\}} m^\mu.$$

Un état final est classé comme parasite si $m_{\max} < m_{\text{seuil}}$, où $m_{\text{seuil}} = 0.95$. Leur fréquence d'apparition est mesurée par

$$R_{\text{parasite}} = \frac{N_{\text{parasites}}}{N_{\text{essais}}}.$$

2.9 Apprentissage de type perceptron

En plus de la règle de Hebb, une règle d'apprentissage de type perceptron est étudiée. Pour chaque souvenir ξ^μ et chaque neurone i , le champ local est

$$h_i^\mu = \sum_{j \neq i} w_{ij} \xi_j^\mu. \quad (17)$$

La condition de stabilité locale est

$$\xi_i^\mu h_i^\mu > 0. \quad (18)$$

Lorsque cette condition n'est pas satisfaite, les poids de la ligne i sont corrigés selon

$$w_{ij} \leftarrow w_{ij} + \frac{\eta_p}{N} \xi_i^\mu \xi_j^\mu, \quad j \neq i, \quad (19)$$

où η_p est le taux d'apprentissage du perceptron.

Cette règle peut être interprétée comme une correction perceptron appliquée indépendamment à chaque neurone du réseau récurrent. Elle vise à rendre les souvenirs stockés stables sous la dynamique du réseau.

Contrairement à la règle de Hebb, cette règle d'apprentissage n'impose pas explicitement la symétrie de la matrice des poids. Elle peut donc introduire une composante antisymétrique dans W . Cependant, l'analyse qui suit montre que, pour les paramètres étudiés, cette composante demeure négligeable devant la partie symétrique.

2.10 Paramètres numériques

Les principaux paramètres utilisés dans les simulations sont résumés au tableau 1. Les valeurs de ces derniers sont précisées au cours de l'explication, puisqu'elles varient parfois au cours de l'analyse.

Paramètre	Symbole
Nombre de neurones	N
Nombre de souvenirs	P
Bruit initial	η
Nombre d'essais	N_{essais}
Seuil de récupération	m_{seuil}
Taux d'apprentissage perceptron	η_p
Nombre maximal d'itérations	n_{max}

TABLE 1 – Paramètres numériques utilisés dans les simulations.

3 Validation du code

Cette section présente les tests effectués afin de vérifier que l'implémentation numérique reproduit les propriétés attendues du modèle de Hopfield.

3.1 Symétrie de la matrice de poids

Pour la règle de Hebb, on vérifie que la matrice des poids est symétrique :

$$W = W^T. \quad (20)$$

On vérifie également que les termes diagonaux sont nuls :

$$w_{ii} = 0. \quad (21)$$

3.2 Décroissance de l'énergie

Dans le cas hebbien avec mise à jour asynchrone, l'énergie doit décroître ou rester constante. Cette propriété est utilisée comme test de validation de la dynamique.




FIGURE 1 – Évolution de l'énergie pour la règle de Hebb. La décroissance de l'énergie valide le comportement attendu de la dynamique asynchrone.

3.3 Stabilité des souvenirs stockés

On vérifie que les souvenirs stockés sont des points fixes de la dynamique lorsque le nombre de souvenirs est suffisamment faible. Pour un souvenir ξ^μ , on teste si

$$\xi^\mu = \text{sgn}(W\xi^\mu). \quad (22)$$

3.4 Validation de la règle perceptron

Pour l'apprentissage perceptron, on vérifie que la règle augmente la stabilité locale des souvenirs en testant la condition

$$\xi_i^\mu h_i^\mu > 0. \quad (23)$$

On mesure également l'asymétrie éventuelle de la matrice finale :

$$\frac{\|W - W^T\|}{\|W\|}. \quad (24)$$

Cette quantité permet de déterminer si la fonction d'énergie classique demeure une bonne approximation qualitative de la dynamique.

4 Résultats

4.1 Robustesse au bruit

La première analyse consiste à mesurer le recouvrement final moyen en fonction du bruit initial η , pour différents nombres de souvenirs stockés.




FIGURE 2 – Recouvrement moyen final en fonction du bruit initial pour différents nombres de souvenirs stockés. À droite, approximation du nombre maximal de souvenirs pour un réseau de $N = 100$.




FIGURE 3 – Comparaison du recouvrement des règles d'apprentissage de type perceptron (gauche) et de Hebb (droite) en fonction du bruit initial, pour plusieurs P avec $N = 100$.

On peut aussi représenter le taux de récupération correcte :

$$R(\eta) = \frac{N_{\text{succès}}}{N_{\text{essais}}}. \quad (25)$$

Un état final est identifié comme parasite si son recouvrement maximal avec les souvenirs stockés est inférieur à un seuil :

$$m_{\max} = \max_{\mu} m^{\mu}. \quad (26)$$

On définit le taux d'états parasites par

$$R_{\text{parasite}} = \frac{N_{\text{parasites}}}{N_{\text{essais}}}. \quad (27)$$

Basin of attraction and parasite states (P=3, N=784), Hebbian learning




FIGURE 4 – Taux de récupération correcte en fonction du bruit initial.

4.2 Effet du nombre de souvenirs stockés

On étudie ensuite l'effet du nombre de souvenirs P sur la performance du réseau, ainsi que l'impact de la similarité des souvenirs.

Lorsque P augmente, les interférences entre souvenirs deviennent plus importantes, ce qui diminue généralement la stabilité des attracteurs. Cela est encore plus vrai pour les souvenirs ayant des contours ou des traits similaires.




FIGURE 5 – Performance de récupération en fonction du nombre de souvenirs stockés, pour des souvenirs similaire pris de la base de données CelebA. $N = 10000$.




FIGURE 6 – Performance de récupération en fonction du nombre de souvenirs stockés, pour des souvenirs générés aléatoirement. $N = 10000$.

4.3 Évolution de l'énergie

L'évolution de l'énergie au cours de la dynamique permet d'étudier la convergence vers un attracteur.




FIGURE 7 – Comparaison de l'évolution de l'énergie pour la règle de Hebb et la règle de type perceptron.




FIGURE 8 – Évolution de l'énergie de 500 souvenirs aléatoires bruité à $\eta = 0.40$ pour un réseau avec apprentissage de type perceptron. $P = 500$ souvenirs aléatoires et $N = 400$.

4.4 CelebA




FIGURE 9 – Recouvrement des visages de CelebA pour un réseau de $N = 10000$ et $P = 4$ à $\eta = 0.45$




FIGURE 10 – Recouvrement des visages de CelebA pour un réseau de $N = 10000$ et $P = 4$ à $\eta = 0.5$

5 Code

Apprentissage de Hebb

```
1  """Hebb training for weight matrix"""
2  @njit
3  def weight_hebb(P: NumpyArray[np.int8]) -> NumpyArray[np.float64]:
4
5      _, N = P.shape
6      Pf = P.astype(np.float64)
7      W = (Pf.T @ Pf) / N
8      np.fill_diagonal(W, 0.0)
9
10     return W
```

Apprentissage de type perceptron

```
1  """Perceptron training for weight matrix"""
2  @njit
3  def weight_perceptron(P: NumpyArray[np.int8]) -> NumpyArray[...]:
4      number_patterns, N = P.shape
5      Pf = np.ascontiguousarray(P.astype(np.float64))
6      W = weight_hebb(P)
7      eta = 0.1
8      n_iter = 0
9      while True:
10         updated = False
11         for pattern in Pf:
12             for i, _ in enumerate(pattern):
13                 W[i, i] = 0
14                 h = 0.0
15                 for j in range(N):
16                     h += W[i, j] * pattern[j]
17                 if pattern[i] * h <= 0:
18                     W[i, :] = W[i, :] + eta * ((pattern[i] * pattern)) /
19                                     N
20                     W[i, i] = 0
21                     updated = True
22             n_iter += 1
23             if (updated == False) or (n_iter == 100_000):
24                 print(n_iter)
25                 break
26     return W
```

6 Analyse et discussion

6.1 Visages CelebA

Cette figure 9 montre que le réseau de Hopfield conserve une très bonne capacité de récupération même lorsque les images initiales sont fortement bruitées, avec un bruit de 45%. Malgré une dégradation importante de l'état initial, les images reconstruites sont pratiquement identiques aux images originales, comme l'indiquent les distances de Hamming finales très faibles, soit 0 ou 1 selon le cas. Cela montre que, pour $P = 4$, les souvenirs stockés possèdent encore des bassins d'attraction suffisamment larges pour corriger une perturbation importante. Cette figure illustre donc clairement la robustesse du réseau dans un régime où le bruit reste légèrement inférieur au seuil critique observé dans les autres analyses.

La figure 10 montre une rupture nette de la capacité de récupération lorsque le bruit initial atteint 50%. Contrairement au cas à 45%, les images finales ne correspondent plus nécessairement aux souvenirs originaux. Certaines convergent vers d'autres visages stockés, tandis que d'autres semblent associées à des états erronés ou inversés. Les distances de Hamming finales sont très grandes, ce qui confirme que la récupération correcte échoue dans ces essais. Ce résultat est cohérent avec l'idée que, près de 50% de bruit, l'état initial ne contient presque plus d'information fiable sur le souvenir cible. Le réseau peut alors basculer dans le bassin d'un autre attracteur ou vers une configuration parasite

6.2 Robustesse et bassins d'attraction

Les résultats montrent que la robustesse du réseau diminue lorsque le bruit initial augmente. Pour de faibles niveaux de bruit, l'état initial demeure dans le bassin d'attraction du souvenir cible et la récupération est généralement correcte. Lorsque le bruit dépasse un certain seuil, l'état initial peut tomber près d'une frontière de bassin ou dans le bassin d'un autre attracteur.

La largeur effective du bassin d'attraction peut être estimée à partir de la courbe $R(\eta)$, donc d'après la figure 4, on peut estimer le bassin d'attraction à $\eta \approx 0.42$.

6.3 Effet du nombre de souvenirs

Lorsque le nombre de souvenirs stockés augmente, les interférences entre souvenirs deviennent plus importantes. Cela réduit la capacité du réseau à reconstruire correctement un souvenir bruité.

Ce comportement est cohérent avec la capacité limitée du réseau de Hopfield classique, qui a une limite de stabilité pour des souvenirs aléatoires de :

$$P_{max} \approx 0.138N \quad (28)$$

On observe à la figure 5 que le nombre maximal de souvenirs similaires qui peuvent rester stables est d'environ 8, et qu'après cela la stabilité chute drastiquement. Si on compare à la figure 6 dans laquelle les souvenirs sont générés aléatoirement, on peut voir une énorme différence de stabilité. En effet Les souvenirs aléatoires ont peu de similarités en moyenne, donc ils interfèrent moins entre eux. On retrouve même environ un autre limite théorique :

$$P < \frac{N}{2\ln N} \longrightarrow P < \frac{10000}{2\ln 10000} \approx 542 \quad (29)$$

On voit sur la figure 6 que la stabilité commence à descendre tranquillement entre 300 et 500 souvenirs.

6.4 Comparaison entre Hebb et perceptron

La figure 7 compare l'évolution de l'énergie pour la règle de Hebb et la règle d'apprentissage de type perceptron. Les deux méthodes présentent une décroissance rapide de l'énergie au début de la dynamique, suivie d'un plateau correspondant à un état stable ou presque stable. Les trajectoires associées au perceptron semblent converger un peu plus rapidement que certaines trajectoires hebbiennes. Cela suggère que le perceptron agit comme une correction locale qui stabilise davantage certains attracteurs. Cependant, les deux comportements restent qualitativement très proches, ce qui indique que la structure énergétique globale demeure similaire dans les conditions testées.

Une comparaison directe de la robustesse au bruit entre l'apprentissage perceptron et hebbien est présentée à la figure 3. Les résultats montrent que le perceptron ne produit pas nécessairement une amélioration globale de la récupération à partir d'états bruités. Cependant, il semble stabiliser les souvenirs exacts d'avantager sans élargir fortement les bassins d'attraction. Donc, pour des niveaux de bruit élevés, les performances du perceptron restent comparables à celles de Hebb. Cette observation appuie l'interprétation selon laquelle le perceptron « creuse » certains attracteurs sans nécessairement augmenter leur largeur effective.

6.5 Interprétation énergétique du perceptron

Dans le cas où la matrice perceptron reste symétrique ou presque symétrique, la fonction d'énergie classique demeure un bon indicateur qualitatif de la dynamique. Cependant, si la matrice devient non symétrique, la décroissance de l'énergie n'est plus garantie théoriquement.

Il est utile de décomposer la matrice des poids en une partie symétrique et une partie antisymétrique :

$$W = W_{\text{sym}} + W_{\text{asym}}, \quad (30)$$

où

$$W_{\text{sym}} = \frac{W + W^T}{2}, \quad W_{\text{asym}} = \frac{W - W^T}{2}. \quad (31)$$

Pour le cas $P = 500, N = 400$, l'asymétrie relative mesurée reste de l'ordre de 10^{-4} , ce qui confirme que la composante antisymétrique est négligeable dans les simulations présentées.

La quantité d'énergie classique dépend essentiellement de la partie symétrique. Ainsi, même si la matrice n'est pas parfaitement symétrique, une décroissance apparente de l'énergie peut être observée si la partie antisymétrique demeure faible.

C'est ce que nous pouvons observer dans les figures 7 et 8.

On voit aussi que dans la figure 8 on observe une chute très rapide de l'énergie au début, suivie d'une relaxation plus lente vers un plateau. Les trajectoires semblent aussi se diviser en deux groupes. Certaines convergent rapidement, tandis que d'autres nécessitent un nombre beaucoup plus élevé de *sweeps*. Cette séparation suggère que certains états initiaux sont immédiatement capturés par un attracteur bien défini, alors que d'autres se trouvent près d'une frontière de bassin ou dans une région métastable, c'est-à-dire que le système est dans une forme d'équilibre temporaire pendant un certain moment et rebascule vers un minima local par la suite. Le perceptron ne semble donc pas provoquer une dynamique chaotique, mais plutôt une dynamique de convergence avec des temps de relaxation très bimodales.

6.6 Limites du modèle et des simulations

Les principales limites de l'étude sont :

- le nombre fini de neurones utilisées dans les simulations ;
- le nombre limité d'essais statistiques ;
- la dépendance aux souvenirs aléatoires générés ;
- l'utilisation d'un seuil arbitraire pour définir une récupération correcte ;
- le coût numérique élevé de l'apprentissage perceptron pour de grands systèmes ;
- le fait que le perceptron stabilise les souvenirs exacts, mais n'optimise pas directement les états bruités.

6.7 Améliorations possibles

Plusieurs extensions pourraient être envisagées :

- utiliser une règle perceptron avec marge de stabilité ;
- entraîner le perceptron sur des versions bruitées des souvenirs ;

- étudier plus systématiquement les états parasites ;
- comparer les dynamiques synchrone et asynchrone ;
- augmenter le nombre d’essais pour obtenir des statistiques plus précises.

7 Conclusion

Ce projet a permis d’étudier numériquement la dynamique d’un réseau de Hopfield bipolaire. Les simulations montrent que le réseau peut reconstruire des souvenirs à partir d’états bruités lorsque le bruit reste suffisamment faible. Cependant, la performance diminue lorsque le nombre de souvenirs stockés augmente, en raison des interférences entre attracteurs.

L’analyse de l’énergie confirme le comportement attendu du modèle de Hopfield classique : sous des dynamique asynchrone et avec une matrice de poids symétrique, l’énergie décroît jusqu’à atteindre un plateau correspondant à un état stable.

La comparaison avec une règle d’apprentissage de type perceptron montre que celle-ci agit principalement comme une correction locale de la stabilité des souvenirs. Elle peut rendre certains attracteurs plus stables, mais ne garantit pas nécessairement un élargissement des bassins d’attraction. Ainsi, stabiliser les souvenirs exacts n’est pas équivalent à améliorer la robustesse globale face au bruit.

Des améliorations futures pourraient consister à utiliser une règle de type perceptron avec marge ou à entraîner le réseau directement sur des versions bruitées des souvenirs, afin d’optimiser non seulement la stabilité des attracteurs, mais aussi la taille de leurs bassins d’attraction.

Références

- [1] J. J. Hopfield, *Neural networks and physical systems with emergent collective computational abilities*, Proceedings of the National Academy of Sciences, 79(8), 2554–2558, 1982.
- [2] J.-E. Campagne, *Éléments sur les réseaux de J. Hopfield et les Machines de Boltzmann de G. Hinton*, 2024.
- [3] A. Alemi, C. Baldassi, N. Brunel, et R. Zecchina, *A Three-Threshold Learning Rule Approaches the Maximal Capacity of Recurrent Neural Networks*, PLoS Computational Biology, 11(8), e1004439, 2015.
- [4] S. Betteti et al., *Input-driven dynamics for robust memory retrieval in Hopfield networks*, Science Advances, 11, eadu6991, 2025.
- [5] T. Wang, *Bias, Basins of Attraction, and Memory Structure in Hopfield Networks*, TechRxiv, 2025.

8 Annexe




FIGURE 11 – Recouvrement des visages de CelebA pour un réseau de $N = 10000$ et $P = 4$ à $\eta = 0.45$, mise à jour synchrone.




FIGURE 12 – Recouvrement des visages de CelebA pour un réseau de $N = 10000$ et $P = 4$ à $\eta = 0.5$, mise à jour synchrone.




FIGURE 13 – Recouvrement des visages de CelebA pour un réseau de $N = 10000$ et $P = 4$ à $\eta = 0.5$ avec apprentissage de type perceptron.